

Московский государственный университет имени М. В. Ломоносова
Факультет вычислительной математики и кибернетики
кафедра математической статистики

Гущин Станислав Алексеевич

Глубокие нейросетевые модели в задачах прогнозирования и детекции аномалий в климатических данных

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Научный руководитель
д.ф.-м.н., доцент
Горшенин Андрей Константинович

Москва, 2026

Оглавление

Введение	3
1 Постановка задачи и критерии оценки	5
1.1 Климатические данные как объект анализа	5
1.2 Станционная и сеточная постановки	5
1.3 Определение аномального события	6
1.4 Метрики качества	6
1.5 Итоговая постановка экспериментов	7
2 Станционная постановка: данные, признаки и базовые модели	8
2.1 Общая схема экспериментального исследования	8
2.2 Станционные данные RusWeather-GF	9
2.3 Построение признаков для станционного прогноза	10
2.3.1 Лаговые признаки	10
2.3.2 Скользящие статистики	10
2.3.3 Календарные признаки	10
2.3.4 Географические признаки	11
2.4 Целевые переменные и событийное преобразование	11
2.5 Baseline-модели	11
2.5.1 Климатология	11
2.5.2 SGD-регрессия	11
2.5.3 Градиентные бустинги	12
2.6 Результаты станционного эксперимента	12
2.7 Интерпретация результатов станционного блока	14
2.8 Роль станционной базовой модели в общей структуре работы	15
3 Глубокая нейросетевая модель для пространственного прогноза осадков	16
3.1 Сеточные данные и региональная постановка	16
3.2 Входные и выходные тензоры модели	17
3.3 Архитектура региональной модели	18
3.3.1 Общая идея архитектуры	18
3.3.2 Структура входного тракта	18
3.3.3 Кодировочная и декодирующая части	19
3.3.4 Условная выходная часть по горизонту и номеру ансамбля	19
3.4 Функция потерь и акцент на экстремумах	19
3.5 Подготовка карт квантилей и событийных меток	20
3.6 Ресурсные ограничения и инженерные аспекты обучения	21

3.7	Почему для этой постановки нужна именно глубокая модель	22
3.8	Промежуточные выводы	22
4	Детекция аномалий и анализ результатов	23
4.1	Постановка эксперимента для региональной модели	23
4.2	Динамика обучения	23
4.3	Качество детекции экстремальных осадков на нативной сетке	24
4.4	Сравнение станционных и сеточных результатов	26
4.5	Детекция аномалий как самостоятельная задача	27
4.6	Калибровка, смещение вероятностей и неопределенность	30
4.7	Выводы по экспериментальной части	34
	Заключение	37
	Список использованных источников	39

Введение

Прогнозирование состояния атмосферы и связанных с ним гидрометеорологических процессов относится к числу наиболее значимых прикладных задач современной науки о данных. От точности прогноза зависят системы раннего предупреждения опасных явлений, управление транспортной инфраструктурой, оценка рисков для энергетики и сельского хозяйства, а также принятие решений в условиях неопределенности. Наиболее сложными для прогноза являются осадки: они обладают выраженной пространственно-временной неоднородностью, сильной асимметрией распределения, большим числом нулевых наблюдений и редкими, но важными экстремальными выбросами.

В последние годы в задачах прогноза погоды активно развиваются нейросетевые подходы, обучаемые на крупных архивах реанализа и наблюдений. Архитектуры GraphCast, Pangu-Weather, FuXi и близкие к ним модели показали, что глубокие модели могут быть конкурентоспособны по сравнению с традиционными системами среднесрочного прогноза [1—3]. При этом практическое использование таких моделей требует аккуратной постановки эксперимента: необходимо определить тип данных, способ задания редкого события, набор метрик качества и базовые модели для сравнения.

В работе рассматриваются две взаимодополняющие постановки. Первая связана со стационарными временными рядами и прогнозом суммарных осадков на горизонтах от 24 до 240 часов. Для нее используются табличное представление данных, признаки на основе лагов и скользящих статистик, а также базовые модели различной сложности. Вторая постановка использует сеточные региональные поля и ориентирована не только на прогноз количества осадков, но и на вероятностную детекцию экстремальных осадочных событий.

Разделение на две постановки не является смешением разных задач. Стационарная часть нужна для проверки того, насколько сильными оказываются простые и хорошо интерпретируемые методы при наличии локальных рядов наблюдений. Сеточная часть нужна для анализа ситуации, где объектом прогноза является целое поле, а значит, требуется модель, способная учитывать пространственную согласованность и многомасштабную структуру атмосферных процессов.

Целью работы является разработка и исследование подходов к прогнозированию осадков и детекции аномальных осадочных событий на основе стационарных и сеточных климатических данных с использованием методов машинного обучения и глубоких нейросетевых моделей.

Для достижения поставленной цели в работе решаются следующие **задачи**:

- 1) сформулировать задачу детекции аномальных осадков через превышение высококвантильного порога;
- 2) подготовить признаки для стационарного прогноза суммарных осадков;
- 3) реализовать и сопоставить климатологию, линейную модель и градиентные бустинги

как базовые методы;

- 4) описать региональную нейросетевую модель для многогоризонтного прогноза осадков на сеточных данных;
- 5) оценить вероятностные характеристики прогноза экстремальных осадков;
- 6) проанализировать ошибки модели по горизонту, пространству, времени и уровню неопределенности.

Объектом исследования являются климатические и метеорологические данные, описывающие осадки на стационарном и сеточном уровнях.

Предметом исследования являются методы машинного обучения и глубокого обучения для прогнозирования осадков и детекции аномальных осадочных событий.

Научная новизна состоит в адаптации единой экспериментальной схемы для анализа осадков как непрерывной величины и как редкого события превышения локального квантильного порога. В работе отдельно рассматриваются сильные стороны стационарных табличных моделей и возможности региональной нейросетевой модели, работающей с пространственными полями.

Практическая значимость связана с тем, что рассмотренные подходы могут использоваться при построении систем краткосрочного и среднесрочного прогноза осадков, а также при оценке риска экстремальных гидроклиматических событий.

Структура работы следующая. В первой главе формулируется постановка задачи и вводятся критерии качества. Во второй главе рассматривается стационарная постановка: данные, признаки и базовые модели. В третьей главе описывается сеточная постановка и архитектура региональной нейросетевой модели. В четвертой главе приводятся результаты экспериментов, графики, калибровка и анализ ошибок. Дополнительные конфигурационные таблицы встроены в основной текст.

1 Постановка задачи и критерии оценки

1.1. Климатические данные как объект анализа

В контексте данной работы под климатическими данными понимаются наблюдательные и модельные данные, описывающие состояние атмосферы и связанных с ней поверхностных процессов. На практике такие данные включают ряды наблюдений метеостанций, продукты реанализа, архивы численных прогнозов и производные показатели, рассчитанные на регулярных пространственных сетках. С точки зрения машинного обучения этот класс данных сочетает свойства временных рядов, пространственных полей и многоуровневых структур.

Осадки являются одной из наиболее сложных переменных. Для них характерны высокая доля нулевых значений, резкие локальные всплески, сильная асимметрия распределения и зависимость от орографии, циркуляции и сезонности. Поэтому модель должна учитывать не только среднее отклонение прогноза, но и способность обнаруживать редкие опасные события. Для задач раннего предупреждения эта способность часто важнее, чем небольшое улучшение средней ошибки.

1.2. Станционная и сеточная постановки

В работе используются два уровня представления данных. В станционной постановке объект соответствует конкретной станции и моменту времени. Модель работает с вектором признаков: лагами осадков и температуры, статистиками по скользящим окнам, календарными и географическими признаками. Такой подход хорошо интерпретируем и вычислительно дешев, но пространственные связи между соседними районами учитываются только косвенно.

В сеточной постановке объектом является пространственное поле или фрагмент поля за несколько предшествующих моментов времени. Вход имеет тензорный вид (T, C, H, W) , где T — число лагов, C — число каналов, H, W — размеры области. Такая постановка требует моделей, способных выделять локальные пространственные шаблоны и более дальние зависимости. Поэтому здесь естественно использовать сверточные блоки, механизмы внимания и архитектуры типа U-Net/Transformer [4—6].

Станционный и сеточный уровни не конкурируют напрямую. Станционная модель полезна для локального прогноза по рядам наблюдений. Сеточная модель нужна, когда требуется пространственно согласованный прогноз и анализ ошибок на карте. В работе эти два уровня используются последовательно: сначала строится сильная табличная базовая модель, затем анализируется более сложная региональная нейросетевая постановка.

1.3. Определение аномального события

В работе аномальное осадочное событие определяется как превышение локального высококвантильного порога. Пусть y — целевая сумма осадков на заданном горизонте, а $q_{0.9}$ — оценка 90-го процентиля исторического распределения для соответствующей станции или ячейки сетки. Тогда бинарная метка события задается как

$$z = \mathbb{I}\{y > q_{0.9}\}.$$

Такое определение позволяет учитывать пространственную и климатическую неоднородность. Один и тот же абсолютный уровень осадков может быть обычным для влажной области и экстремальным для сухой области; квантильный порог учитывает это различие.

Из непрерывного прогноза $\hat{y}$ можно получить вероятность события через сглаженное сравнение с порогом:

$$p = \sigma\left(\frac{\hat{y} - q_{0.9}}{T}\right),$$

где σ — логистическая функция, а $T > 0$ — температурный параметр. Эта схема связывает регрессионный прогноз с задачей детекции редких событий без построения отдельного классификатора.

1.4. Метрики качества

Для непрерывного прогноза осадков могут использоваться RMSE, MAE и связанные с ними показатели. Однако в данной работе основной упор делается на событийную оценку, то есть на качество различения экстремальных и обычных случаев. Поэтому используются ROC-AUC, ROCSS, PR-AUC и Brier score [7—10].

ROC-AUC показывает, насколько хорошо модель ранжирует положительные и отрицательные случаи. ROC skill score выражается через ROC-AUC следующим образом:

$$\text{ROCSS} = 2 \cdot \text{ROC-AUC} - 1.$$

Значение ROCSS, близкое к нулю, соответствует случайному ранжированию, а положительное значение означает наличие полезного сигнала.

PR-AUC дополнительно важна для редких событий, поскольку она чувствительна к дисбалансу классов. Brier score оценивает среднеквадратичную ошибку вероятностного прогноза:

$$\text{BS} = \frac{1}{N} \sum_{i=1}^N (p_i - z_i)^2.$$

При анализе пространственных полей метрики дополнительно взвешиваются по площади ячеек через множитель, пропорциональный $\cos \varphi$, где φ — широта. Это нужно потому, что ячейки широтно-долготной сетки имеют разную площадь [11].

1.5. Итоговая постановка экспериментов

В первой экспериментальной части решается задача стационарного прогноза суммарных осадков на горизонтах 24, 72, 120 и 240 часов. Прогноз строится по лаговым, агрегированным, календарным и географическим признакам. Результаты климатологии, линейной модели, LightGBM и XGBoost сравниваются по событийным метрикам.

Во второй экспериментальной части используется региональная нейросетевая модель для сеточных полей. Она принимает последовательность пространственных полей и выдает многогоризонтный прогноз осадков. Вероятность аномального события вычисляется относительно локальной карты порогов $q_{0.9}$. Таким образом, обе части работы связаны общей формализацией аномалии, но используют разные представления данных и разные классы моделей.

2 Станционная постановка: данные, признаки и базовые модели

2.1. Общая схема экспериментального исследования

В рамках данной работы экспериментальное исследование строится как последовательное решение задачи прогнозирования метеорологических характеристик по пространственно-временным данным. Исходной основой выступает набор RusWeather-GF, содержащий погодные поля и связанные с ними наблюдения, представленные в форме, пригодной для машинного обучения. Основная цель экспериментов состоит в том, чтобы по историческому фрагменту климатических данных восстановить закономерности их изменения и получить прогноз целевых переменных на заданном горизонте.

Общая схема исследования включает несколько логически связанных этапов. На первом этапе выполняется подготовка данных: выбираются используемые метеорологические признаки, формируются пространственно-временные последовательности наблюдений, данные приводятся к согласованному формату и разделяются на обучающую, валидационную и тестовую выборки. Такой этап необходим для того, чтобы обеспечить корректное обучение моделей и сопоставимость результатов.

На втором этапе формулируется задача прогноза как задача отображения истории наблюдений в будущее состояние системы. Иными словами, модель получает на вход некоторый временной интервал предшествующих измерений и должна предсказать значения интересующих погодных характеристик на следующих шагах. В зависимости от постановки эксперимента прогноз может рассматриваться как детерминированный или вероятностный, что особенно важно при анализе экстремальных погодных явлений.

На третьем этапе обучаются глубокие нейросетевые модели, способные учитывать как временные зависимости в данных, так и пространственную структуру метеорологических полей. Сравнение моделей проводится в единой экспериментальной постановке, что позволяет оценивать вклад архитектурных решений не изолированно, а в контексте общей задачи прогноза.

На заключительном этапе выполняется оценка качества полученных результатов. Рассматриваются стандартные метрики точности прогноза, а также характеристики, связанные с устойчивостью модели к редким и аномальным наблюдениям. Отдельное внимание уделяется анализу экстремальных ситуаций, поскольку именно в таких режимах наиболее важны практическая применимость модели и надёжность её выводов.

Таким образом, экспериментальная процедура в работе следует понимать не как техническую последовательность действий внутри вычислительного ноутбука, а как общую исследовательскую схему, связывающую данные RusWeather-GF, постановку задачи прогноза, обучение моделей и анализ их качества на климатических данных.

2.2. Станционные данные RusWeather-GF

В станционной части работы используется набор данных RusWeather-GF. Каждая запись содержит идентификатор станции, дату наблюдения, значения температуры и осадков, а также географические характеристики станции: широту, долготу и высоту. В качестве целевой переменной используется **precipitation**, а температура рассматривается как дополнительный динамический предиктор.

Частота наблюдений определяется автоматически как 24 часа. Это позволяет естественным образом формулировать целевые горизонты:

TP24, TP72, TP120, TP240,

что соответствует прогнозу суммарных осадков на 1, 3, 5 и 10 суток вперед. Такая постановка удобна по двум причинам. Во-первых, горизонты охватывают как краткосрочный, так и среднесрочный режим прогноза. Во-вторых, они хорошо согласуются с практикой предупреждения опасных осадочных событий, для которых важны как ближайшие сутки, так и несколько суток вперед.

Объем исходного станционного массива достаточно велик: порядка 8.9 млн строк наблюдений. После временного разбиения с учетом *ridge*-горизонта получены следующие объемы:

Разбиение	Число строк	Комментарий
Train	6 409 702	обучающая часть
Validation	1 276 786	валидационная часть
Test	1 196 665	тестовая часть

Параметр	Значение
Целевая переменная	сумма осадков
Дополнительный динамический признак	температура
Горизонты прогноза	24, 72, 120, 240 часов
Лаги	1, 3, 6, 12, 24, 48, 72, 120, 240 часов
Скользющие окна	3, 6, 12, 24, 72, 120, 240 часов
Порог экстремальности	$q_{0.9}$
Минимум наблюдений для порога	50 на станцию
Доли train/val/test	0.70 / 0.15 / 0.15
Защитный интервал	240 часов

Таблица 2.1: Основные параметры подготовки станционных данных

Использование `purge`-интервала в 240 часов позволяет избежать утечки информации между соседними участками времени при многогоризонтном прогнозе. Иначе наблюдения, близкие к границе `train/validation` или `validation/test`, могли бы использовать близкие целевые значения и тем самым искусственно завышать качество.

2.3. Построение признаков для стационарного прогноза

Одним из центральных элементов стационарной постановки является инженерия признаков. В работе используется несколько классов признаков.

2.3.1. Лаговые признаки

Для осадков и температуры формируются лаги с набором горизонтов

1, 3, 6, 12, 24, 48, 72, 120, 240 часов.

Поскольку фактический шаг данных составляет 24 часа, часть этих значений сопоставляется доступной сетке времени. Лаговые признаки отражают краткосрочную инерцию и сезонно-синоптическую структуру процесса. Для осадков это особенно важно: наличие осадков в предшествующие дни повышает вероятность сохранения влажного режима, тогда как после сухого периода вероятность экстремума ниже.

2.3.2. Скользящие статистики

Для тех же окон времени строятся скользящие статистики: среднее, сумма и стандартное отклонение. Сумма по окну интерпретируется как интегральная характеристика накопленной влаги, среднее — как усредненный фон, а стандартное отклонение — как индикатор нестабильности процесса. В задачах экстремальных осадков такие статистики особенно полезны, поскольку экстремум часто возникает не изолированно, а на фоне уже аномального режима.

2.3.3. Календарные признаки

Используются признаки месяца, а также `day-of-year`. Это позволяет модели учитывать сезонность. Для осадков сезонная компонента критична: характер распределения и интенсивность осадков существенно различаются между холодным и теплым сезоном, а также по регионам. Календарные признаки дают модели компактное представление этой сезонной структуры.

2.3.4. Географические признаки

В качестве статических признаков используются широта, долгота и высота станции. Эти переменные частично компенсируют отсутствие явной пространственной структуры в табличной постановке. Например, горные районы и приморские области обладают иным режимом осадков, чем континентальные равнинные территории. В станционной модели координаты не создают полноценной карты, но дают алгоритму возможность различать регионы с разной климатической нормой.

2.4. Целевые переменные и событийное преобразование

Для каждого временного шага формируются целевые переменные TR24, TR72, TR120, TR240, представляющие будущие суммы осадков на соответствующих горизонтах. Модели обучаются в регрессионной постановке, то есть минимизируют ошибку по непрерывной величине.

Однако сама логика работы требует анализа не только непрерывного прогноза, но и способности модели выделять аномальные случаи. Поэтому валидация строится через высоквантильные события. Для каждой станции и каждого горизонта оценивается порог $q_{0.9}$ при условии достаточного числа наблюдений (минимум 50 значений на станцию). Далее для фактического значения формируется бинарная метка превышения порога, а из непрерывного прогноза выводится вероятность события через температурно-сглаженное сравнение с $q_{0.9}$.

Такая схема имеет несколько достоинств. Во-первых, она позволяет использовать одну и ту же регрессионную модель одновременно для прогноза величины и для детекции аномалий. Во-вторых, она локально адаптивна: порог экстремальности зависит от станции. В-третьих, метрики ROC-AUC, ROCSS, PR-AUC и Brier дают более содержательную картину для прикладного использования, чем усредненная квадратичная ошибка.

2.5. Baseline-модели

2.5.1. Климатология

Климатологическая базовая модель строится как среднее значение осадков по станции и месяцу. Для каждого горизонта вычисляется станционно-месячное среднее, которое и используется как прогноз. Несмотря на простоту, климатология является сильным ориентиром, потому что она уже учитывает устойчивую сезонную компоненту и региональную специфику станции.

2.5.2. SGD-регрессия

В качестве линейной базовой модели использована модель `SGDRegressor` с квадратичной функцией потерь и `elastic net`-регуляризацией. Обучение организовано по схеме

`partial_fit` с несколькими эпохами прохода по шардированным данным. Эта модель важна как интерпретируемая отправная точка: если даже линейная модель показывает удовлетворительное качество, сложные алгоритмы должны оправдывать свою стоимость приростом метрик.

2.5.3. Градиентные бустинги

Основными табличными моделями являются LightGBM и XGBoost. Обе модели обучаются инкрементно блоками по 100 итераций до общего лимита 500 раундов. Такой режим согласуется с выбранной метрикой отбора `mean_rocss_val`, то есть средним ROCSS по горизонтам валидации. Использование именно ROCSS как селекционной метрики принципиально: оно задает приоритет способности модели детектировать экстремальные события, а не только минимизировать регрессионную ошибку.

Параметр	LightGBM	XGBoost
Функция потерь	регрессия	квадратичная ошибка
Скорость обучения	0.05	0.05
Число итераций	500	500
Глубина / листья	31 лист	глубина 6
Подвыборка объектов	0.9	0.9
Подвыборка признаков	0.9	0.9
Случайное зерно	42	42

Таблица 2.2: Основные параметры бустинговых моделей

2.6. Результаты стационарного эксперимента

В таблице 2.3 приведены усредненные событийные метрики на валидационной выборке для всех реализованных стационарных моделей. Численные значения восстановлены непосредственно из результатов ноутбука.

Модель	mean ROC-AUC	mean ROCSS	mean PR-AUC	mean Brier
Климатология	0.7062	0.4124	0.2023	0.1232
SGD	0.4666	-0.0667	0.0927	0.1658
LightGBM	0.7213	0.4425	0.2158	0.1249
XGBoost	0.7235	0.4469	0.2170	0.1247

Таблица 2.3: Средние событийные метрики на валидации для стационарных моделей

Из таблицы видны несколько принципиальных выводов.

Во-первых, климатология оказывается сильной базовой моделью. Ее средний ROCSS равен 0.4124, что существенно выше случайного уровня и указывает на высокую значимость сезонно-климатической компоненты в данных. Это важный результат: любая сложная модель в задачах осадков должна превосходить не «нулевой» базовая модель, а именно сильную климатологию.

Во-вторых, линейная модель SGD демонстрирует неудовлетворительное качество. Средний ROCSS отрицателен, а Brier score заметно хуже, чем у остальных моделей. Это говорит о том, что зависимость между признаками и целевыми осадками не может быть адекватно описана простой линейной комбинацией признаков. Даже богатая инженерия признаков не компенсирует отсутствие нелинейности.

В-третьих, ансамблевые бустинги уверенно превосходят климатологию и линейную модель. Между LightGBM и XGBoost разрыв невелик, однако XGBoost дает лучшие средние значения ROC-AUC, ROCSS и PR-AUC. Следовательно, в рамках стационарной постановки именно градиентные бустинги представляют наилучший компромисс между качеством и вычислительной реализуемостью.

Для более детального анализа в таблице 2.4 приведены результаты по отдельным горизонтам.

Горизонт	Модель	ROC-AUC	ROCSS	PR-AUC	Brier
24 ч	Климатология	0.6267	0.2535	0.1512	0.1394
	SGD	0.5140	0.0280	0.1067	0.1625
	LightGBM	0.6871	0.3743	0.1986	0.1374
	XGBoost	0.6905	0.3809	0.2007	0.1370
72 ч	Климатология	0.7022	0.4044	0.1962	0.1184
	SGD	0.4638	-0.0724	0.0911	0.1588
	LightGBM	0.7131	0.4262	0.2084	0.1202
	XGBoost	0.7151	0.4302	0.2093	0.1200
120 ч	Климатология	0.7294	0.4587	0.2161	0.1167
	SGD	0.4514	-0.0972	0.0880	0.1650
	LightGBM	0.7285	0.4570	0.2186	0.1195
	XGBoost	0.7298	0.4596	0.2192	0.1194
240 ч	Климатология	0.7664	0.5329	0.2458	0.1184
	SGD	0.4373	-0.1253	0.0848	0.1766
	LightGBM	0.7563	0.5126	0.2375	0.1224
	XGBoost	0.7584	0.5169	0.2385	0.1222

Таблица 2.4: Валидационные метрики по отдельным горизонтам прогноза

Эта таблица позволяет сделать более тонкие наблюдения.

На горизонте 24 часа бустинги дают явное преимущество над климатологией. Здесь свежая динамика и нелинейное сочетание признаков наиболее информативны, поэтому XGBoost и LightGBM существенно улучшают ранжирование экстремальных случаев.

На горизонтах 72 и 120 часов преимущество бустингов сохраняется, но становится умеренным. Можно сделать вывод, что модель уже больше опирается на медленные режимные закономерности, и вклад сложной нелинейности снижается. Тем не менее XGBoost по-прежнему удерживает наилучшие значения ROC-AUC и ROCSS.

На горизонте 240 часов картина меняется: климатология становится сильнейшей моделью по всем основным событийным метрикам. Это очень важный эмпирический вывод. Для дальнего горизонта стационарные признаки из прошлого уже не обеспечивают достаточно устойчивой информации, и доминировать начинает долгосрочная климатическая структура по станции и сезону. Следовательно, глубокие и сложные модели не обязаны превосходить климатологию на дальних горизонтах, если в них отсутствует явное пространственное представление крупномасштабной циркуляции.

2.7. Интерпретация результатов стационарного блока

Полученные результаты позволяют сформулировать несколько выводов, значимых не только для данной работы, но и для общей постановки прогнозирования осадков.

Первый вывод состоит в том, что инженерия признаков действительно работает. Даже без нейросетевых методов табличное представление на стационарном уровне способно обеспечить хорошее качество событийного ранжирования. Это означает, что для прикладных систем локального прогноза бустинговые модели представляют собой разумную и сильную базовую модель.

Второй вывод связан с ограничениями стационарного подхода. Хотя бустинги хорошо работают на коротких и средних горизонтах, они не моделируют пространственную структуру осадков в явном виде. Любая зависимость между соседними районами выражается только косвенно через координаты, а это ограничивает способность модели улавливать крупномасштабные атмосферные процессы. Именно поэтому для сеточного прогноза и пространственной детекции аномалий требуется другой класс моделей.

Третий вывод касается самого понятия аномалии. В стационарной части работы аномалия успешно формализуется как локальное превышение квантильного порога. Это позволяет перейти от регрессионной задачи к вероятностной без смены модели и без необходимости строить отдельный классификатор. Такая формализация будет использована и в сеточной части, но уже на уровне пространственных карт $q_{0.9}$.

2.8. Роль стационарной базовой модели в общей структуре работы

Несмотря на то что официальная тема работы фокусируется на глубоких нейросетевых моделях, стационарная глава имеет принципиальное значение. Она выполняет три функции.

Во-первых, она задает нижнюю и среднюю планку качества. Сильный бустинговый базовая модель необходим для того, чтобы последующее использование глубокой модели не выглядело неоправданным усложнением.

Во-вторых, она позволяет отделить эффект «более богатых данных» от эффекта «более сложной архитектуры». Если одна лишь инженерия признаков и нелинейный табличный алгоритм уже дают хороший результат, значит, дальнейшее улучшение должно происходить за счет перехода к пространственно-согласованному представлению данных.

В-третьих, стационарный блок задает язык интерпретации. Через него удобно объяснить, почему событийные метрики, квантильные пороги и вероятностная оценка редких событий более релевантны прикладной задаче, чем только RMSE или MAE. В дальнейшем та же логика переносится на сеточный прогноз, где аномалии уже детектируются как экстремальные осадки по картам квантилей.

Таким образом, стационарная базовая модель не является в работе побочным сюжетом. Она выступает как методологическая основа, на фоне которой можно содержательно оценивать вклад глубоких нейросетевых моделей в задачах прогнозирования и детекции аномалий в климатических данных.

3 Глубокая нейросетевая модель для пространственного прогноза осадков

3.1. Сеточные данные и региональная постановка

Во второй части работы используются сеточные региональные данные, подготовленные в формате, совместимом с бенчмарком WeatherBench 2 [11]. В отличие от стационарного массива, здесь каждый объект представляет собой не вектор признаков, а пространственное поле нескольких метеорологических переменных на регулярной сетке. Это позволяет перейти от моделирования локальной точки к моделированию согласованной региональной картины осадков.

Согласно конфигурации нового ноутбука используются два основных набора данных:

1. обучающий набор на сетке 0.25° ;
2. валидационный набор 2020 года на той же сетке 0.25° .

Размер сетки 0.25° в рассматриваемом регионе равен 159×219 . Временной охват обучающей части составляет период с 2013-01-01 по 2019-12-29, а валидация охватывает данные 2020 года. Такое разбиение соответствует корректной временной постановке и позволяет моделировать перенос на следующий год без перемешивания временных слоев.

Для формирования входов используются иницилирующие моменты с шагом 6 часов. В обучении допускаются все четыре инициализации внутри суток $\{0, 6, 12, 18\}$, тогда как в валидации используются инициализации $\{0, 12\}$, что согласуется с практикой регулярного прогноза. По логам подготовки данных получены:

Набор	Число примеров	Комментарий
Train init	10 168	последовательности для обучения
Validation 0.25	732	выровненные валидационные запуски

Параметр	Значение
Размер входного поля	159×219
Лаги	48, 42, 36, 30, 24, 18, 12, 6, 0 часов
Горизонты прогноза	24, 48, 72, 96, 120, 144, 168, 192, 216, 240 часов
Число членов ансамбля	4
Базовая размерность	64
Размер окна внимания	4
Число голов внимания	4 на первом transformer-уровне, 8 в bottleneck
Число эпох в конфигурации	30
Фактически сохраненная история	12 эпох
Размер батча	1
Накопление градиента	64 шага
Скорость обучения	10^{-4}
Весовая регуляризация	10^{-4}
Температура события при инференсе	0.25

Таблица 3.1: Основные параметры региональной модели Earthformer-M в новом запуске

3.2. Входные и выходные тензоры модели

На вход модели подаются динамические и статические признаки. Число динамических каналов равно 15, а число статических — 2. Динамические каналы включают метеорологические переменные на последовательности из девяти лагов:

48, 42, 36, 30, 24, 18, 12, 6, 0 часов.

Следовательно, один объект имеет вид

$$x_{\text{dyn}} \in \mathbb{R}^{9 \times 15 \times 159 \times 219}, \quad x_{\text{static}} \in \mathbb{R}^{2 \times 159 \times 219}.$$

Модель должна выдать прогноз на десять горизонтов прогноза:

24, 48, 72, 96, 120, 144, 168, 192, 216, 240 часов.

Одновременно прогнозируется несколько членов ансамбля, в конфигурации ноутбука их число равно четырем. Поэтому выходные тензоры имеют размерность

$$\hat{y}_{tp} \in \mathbb{R}^{B \times 4 \times 10 \times 159 \times 219}, \quad \hat{y}_{evt} \in \mathbb{R}^{B \times 4 \times 10 \times 159 \times 219},$$

где B — размер батча, $\hat{y}_{tp}$ — логарифм прогноза осадков, а $\hat{y}_{evt}$ — логиты вспомогательной вероятности экстремального события.

Важно подчеркнуть, что региональная модель решает задачу *многогоризонтного* прогноза. В отличие от стационарного блока, где каждый горизонт фактически рассматривается как отдельная целевая переменная в табличной модели, здесь все горизонты прогноза предсказываются общей архитектурой. Это соответствует современным подходам в нейросетевом прогнозе погоды, где одна модель захватывает общие представления и распределяет их по нескольким горизонтам прогноза.

3.3. Архитектура региональной модели

3.3.1. Общая идея архитектуры

В новом эксперименте используется модель Earthformer-M. Она заменяет предыдущий вариант региональной модели и ближе соответствует transformer-подходу к пространственно-временному прогнозу: временная ось не схлопывается сразу после входа, а сначала обрабатывается 3D-свертками и cuboid-attention блоками. Архитектура сочетает несколько идей:

1. отдельную обработку динамических и статических каналов;
2. 3D-сверточный входной тракт для сохранения временного контекста;
3. иерархическое кодирование с ConvNeXt-блоками и cuboid transformer-блоками;
4. temporal attention pooling перед декодером;
5. условную выходную часть, зависящую от номера горизонта прогноза и члена ансамбля.

Такой дизайн хорошо соответствует структуре климатических данных. Сверточные блоки эффективно обрабатывают локальные паттерны, связанные с орографией и перемещением осадочных систем, тогда как cuboid-attention блоки позволяют учитывать связи одновременно по времени и пространству. Наличие отдельных статических каналов важно для учета топографии и других неизменных характеристик региона.

3.3.2. Структура входного тракта

Динамическая часть модели начинается с двух 3D-сверток с ядром $3 \times 3 \times 3$. Благодаря этому лаговая ось сохраняется на ранних этапах, и модель может учитывать не только

отдельные карты, но и локальную эволюцию полей во времени. Это является главным отличием от более простого варианта, где временной контекст сворачивался почти сразу.

Статическая часть проходит через отдельный двумерный сверточный stem. Затем статические признаки расширяются вдоль временной оси и объединяются с динамическими признаками с помощью $1 \times 1 \times 1$ -свертки. Такой способ слияния позволяет модели учитывать как текущее состояние атмосферы, так и неизменные особенности подстилающей поверхности.

3.3.3. Кодировущая и декодирующая части

На полном пространственном разрешении используются time-distributed ConvNeXt-блоки [6]. После этого модель выполняет два уровня пространственного понижения разрешения с помощью 3D-downsample-блоков. На пониженных разрешениях применяются cuboid transformer-блоки: два блока на первом transformer-уровне и четыре блока в центральной части модели. Размер cuboid-окна по времени равен 3, а по пространственным направлениям равен 5×5 , поскольку он задается как `window_size + 1`.

Перед декодером временная ось агрегируется не простым средним, а блоком temporal attention pooling. После этого декодер восстанавливает пространственное разрешение через up-блоки с пропуском признаков из кодировущей части. Первый up-блок использует гибридную структуру со вниманием, второй — сверточную обработку. Такая схема сохраняет идею U-Net [4], но переносит ее в многогоризонтную пространственно-временную постановку.

3.3.4. Условная выходная часть по горизонту и номеру ансамбля

Финальный выход формируется модулем условной выходной части. Для каждого горизонта прогноза и каждого ансамблевого члена строятся embedding-представления, которые затем используются в FiLM-подобной модуляции признаков. Это важно по двум причинам.

Во-первых, разные горизонты прогноза требуют разных представлений. Ошибки на 24 часа и на 240 часов имеют разную природу, и полезно позволить модели учитывать это различие в выходном слое. Во-вторых, наличие нескольких ансамблевых членов позволяет получать не только среднее поле, но и оценивать неопределенность. В задачах детекции экстремальных осадков именно ансамблевая постановка дает возможность перейти от жесткого детерминированного решения к вероятностному прогнозу.

3.4. Функция потерь и акцент на экстремумах

В новом запуске функция потерь стала более явно ориентированной на вероятностную детекцию превышения $q_{0.9}$. В итоговую функцию входят регрессионный Huber-loss по среднему ансамбля, квантильная функция потерь по ансамблевым членам, soft-event loss от

носителем локального порога, Brier-компонента и вспомогательная событийная голова:

$$\mathcal{L} = 0.35\mathcal{L}_{\text{tp}} + 0.45\mathcal{L}_{\text{q}} + 0.90\mathcal{L}_{\text{soft-evt}} + 0.20\mathcal{L}_{\text{Brier}} + 0.10\mathcal{L}_{\text{evt}}. \quad (3.1)$$

Регрессионная часть удерживает физический прогноз осадков, а квантильная часть предотвращает вырождение всех ансамблевых членов в одинаковое значение. Это важно, потому что вероятность события при инференсе получается из доли членов ансамбля, превышающих локальный порог $q_{0.9}$. Если ансамбль не разнообразен, такая вероятность становится малоинформативной.

Главная событийная компонента строится не только по вспомогательному логиту, но и по прогнозу осадков относительно карты $q_{0.9}$:

$$p_{\text{soft}} = \sigma \left(\frac{\hat{y}_{\text{tp}} - q_{0.9}}{T_{\text{soft}}} \right), \quad T_{\text{soft}} = 0.35.$$

Также используется Brier-компонента, напрямую связанная с качеством вероятностного прогноза. Для редких событий применяется focal BCE с усилением положительного класса; при этом положительный вес берется в сглаженном виде через степень 0.5, чтобы не переусилить редкий класс.

С методологической точки зрения это важное изменение. Обычная регрессия по осадкам склонна оптимизировать среднее качество и, следовательно, уделять чрезмерное внимание многочисленным малым или нулевым значениям. Новая функция потерь специально усиливает события около локального порога и экстремальные случаи, поэтому лучше соответствует задаче вероятностной детекции аномалий.

3.5. Подготовка карт квантилей и событийных меток

Для сеточной постановки аномалии также определяются через превышение квантиля $q_{0.9}$, но порог хранится в виде *карты* для каждой ячейки сетки. Это означает, что экстремальность определяется локально по каждой ячейке. Такой подход необходим, поскольку распределение осадков неоднородно по региону: морские области, горные районы и континентальные зоны имеют разные характерные уровни и дисперсии. Локальная карта порогов делает критерий аномальности физически и статистически осмысленным.




Рис. 3.1: Пространственное распределение локального порога $q_{0.9}$ для определения экстремальных осадков. На рисунке показано, что один общий порог для всего региона был бы слишком грубым приближением.

На рисунке 3.1 видно, что порог экстремальности заметно меняется по пространству. Поэтому я не использую единый абсолютный порог осадков для всего региона: одно и то же значение суточной суммы может быть нормальным для влажной горной или прибрежной области и одновременно аномальным для более сухой континентальной зоны. Такой способ задания события делает дальнейшие метрики более честными по отношению к климатическим различиям внутри области.

Итоговые метрики считаются не только для вспомогательной головной части события, но и для вероятностной интерпретации прогноза TP24h относительно локального порога. Такое решение согласуется с логикой вероятностной оценки гидроклиматического события, где основное внимание уделяется качеству прогнозируемого гидроклиматического события, а не только внутреннему сигнальному каналу модели.

3.6. Ресурсные ограничения и инженерные аспекты обучения

Еще одной важной частью исследования является учет вычислительных ограничений. Новый запуск выполнялся в среде Colab на графическом процессоре Tesla T4. Поэтому фактическая конфигурация была уменьшена относительно более тяжелого варианта: базовая размерность равна 64, размер батча равен 1, а число шагов накопления градиента равно 64. Это позволяет обучать модель на сетке 0.25° , сохраняя полный набор горизонтов и четыре ансамблевых члена.

Также включена gradient checkpointing, которая уменьшает использование памяти ценой дополнительного времени вычисления. Этот аспект не является второстепенным: в задачах климатического глубокого обучения инженерная реализуемость модели часто столь же важна, как и ее теоретическая выразительность.

В логах обучения явно контролируется численная устойчивость: проверяются значения NaN и Inf во входных данных, статистиках нормировки, параметрах модели и промежу-

точных предсказаниях. Такое внимание к диагностике особенно важно в задачах осадков, где распределение целевой переменной резко асимметрично и может провоцировать нестабильность при переходе к логарифмическому пространству или при работе с экстремальными случаями.

3.7. Почему для этой постановки нужна именно глубокая модель

Теперь можно ответить на принципиальный вопрос: почему вторая часть работы не ограничивается табличными алгоритмами, а требует глубокой нейросетевой архитектуры?

Во-первых, вход имеет высокую размерность и естественную пространственную топологию. Если развернуть поле 159×219 по всем каналам и лагам в один вектор, размерность станет чрезвычайно большой, а локальная структура будет уничтожена. Сверточные и transformer-блоки позволяют использовать эту структуру напрямую.

Во-вторых, задача требует согласованного прогноза на нескольких горизонтах прогноза и по нескольким ансамблевым членам. Табличный подход скорее привел бы к набору независимых моделей, каждая из которых не использовала бы общие представления процесса. Глубокая модель, наоборот, естественно извлекает общее скрытое представление и далее специализирует его по горизонту.

В-третьих, детекция аномалий в климатических полях зависит не только от значения в одной ячейке, но и от окружающего контекста: формы осадочной системы, орографического усиления, фронтальных структур, адвекции влаги. Такие зависимости трудно выразить через ручные признаки, но именно они являются сильной стороной глубоких сетей.

Наконец, глубокая модель позволяет объединить в одной архитектуре регрессию по сумме осадков и вспомогательную задачу событийного прогнозирования. Это делает постановку ближе к реальному сценарию риск-ориентированного прогнозирования, когда пользователю важны и ожидаемая интенсивность, и вероятность опасного эпизода.

3.8. Промежуточные выводы

Таким образом, сеточная часть работы формирует полноценную глубокую постановку задачи. Региональная модель Earthformer-M получает на вход многоканальные последовательности полей, сохраняет временной контекст в 3D-сверточном тракте, использует cuboid transformer-блоки на пониженных разрешениях, обучается на комбинации регрессионных и событийных функций потерь и оценивается на валидационном периоде 2020 года. В следующей главе будет показано, как результаты этой модели соотносятся с базовой постановкой, какие качественные закономерности проявляются в метриках и что можно сказать о способности модели выделять экстремальные осадочные события на основе доступных экспериментальных логов.

4 Детекция аномалий и анализ результатов

4.1. Постановка эксперимента для региональной модели

В региональном эксперименте целью является не только получение прогнозного поля осадков, но и оценка способности модели детектировать экстремальные осадки как аномальные события. Для этого прогнозируемые суммы осадков сравниваются с картами порогов $q_{0.9}$, после чего вычисляются вероятности и событийные метрики. Важное отличие от стационарной части состоит в том, что здесь оценка производится по всему пространственному полю с учетом взвешивания по площади и региональных масок.

В этой главе приведены результаты нового ноутбука с моделью Earthformer-M. Визуализации получены из сохраненных артефактов лучшего запуска на сетке 0.25° ; для вставки в текст они приведены с русскими подписями, чтобы оформление было единообразным.

4.2. Динамика обучения

Первой важной характеристикой является стабильность обучения. По графику истории видно, что общий train loss уменьшается примерно с 1.28 на первой эпохе до 0.61 к двенадцатой эпохе. Это означает, что оптимизация остается устойчивой и не проявляет признаков численной неустойчивости. Это согласуется и с дополнительными проверками на NaN/Inf, встроенными в алгоритм: параметры и предсказания оставались конечными.

Для событийной постановки важнее не только значение функции потерь, но и якорная метрика ROCSS. На сетке 0.25° средний ROCSS по горизонтам 72, 120 и 240 часов сначала растет с уровня около 0.17, затем выходит на плато около 0.24--0.26. Максимум на графике достигается приблизительно на девятой эпохе. На дополнительной оценке 1.5° значения заметно ниже и находятся около 0.03--0.06, что показывает чувствительность результата к протоколу оценки и разрешению.




Рис. 4.1: Динамика обучения региональной модели Earthformer-M: изменение функции потерь и валидационной skill-метрики по эпохам.

График на рисунке 4.1 удобен тем, что показывает не только численное снижение функции потерь, но и момент насыщения событийного качества. По нему видно, что уменьшение функции потерь продолжается, однако выигрыш по якорной метрике после первых эпох становится ограниченным. Поэтому дальше я рассматриваю не только значение функции потерь, но и набор специальных метрик для редких событий.

Эпоха	Train loss	ROCSS 0.25 Europe	ROCSS 1.5 Europe
1	≈ 1.28	≈ 0.17	≈ 0.03
4	≈ 0.68	≈ 0.24	≈ 0.05
7	≈ 0.65	≈ 0.25	≈ 0.06
9	≈ 0.64	≈ 0.26	≈ 0.05
12	≈ 0.61	≈ 0.24	≈ 0.05

Таблица 4.1: Динамика якорной метрики по истории нового запуска; значения восстановлены по графику и округлены

Содержательно таблица 4.1 показывает, что оптимальное качество по событийной метрике достигается раньше, чем минимальное значение функции потерь. Это типичная ситуация для задач с редкими событиями: дальнейшее улучшение общей функции потерь не обязательно улучшает качество по экстремумам. Следовательно, для отбора лучшего чекпоинта необходимо ориентироваться именно на вероятностные метрики редких событий, а не только на обобщенную функцию потерь.

4.3. Качество детекции экстремальных осадков на нативной сетке

Наиболее содержательными для интерпретации являются метрики на конкретных горизонтах. В новом запуске модель очень сильна на ближайшем горизонте 24 часа: для Европы ROC-AUC равен 0.9017, ROCSS равен 0.8034, PR-AUC равен 0.4065. После этого качество быстро снижается с ростом горизонта прогноза. На горизонтах 72, 120 и 240 часов ROCSS остается положительным, но уже находится на уровнях 0.3287, 0.2352 и 0.1738 соответственно.




Рис. 4.2: Зависимость основных вероятностных метрик от горизонта прогноза. На графике собраны ROCSS, ROC-AUC, PR-AUC и Brier score для разных горизонтов прогноза.

Рисунок 4.2 хорошо иллюстрирует резкую деградацию качества после первых суток. Для осадков это ожидаемо, поскольку поле осадков имеет высокую пространственную неоднородность и сильную зависимость от синоптической ситуации. При этом важное отличие нового запуска состоит в том, что Brier score на средних и дальних горизонтах заметно ухудшается и держится около 0.30. Это указывает, что модель сохраняет некоторую способность ранжировать риск, но вероятности требуют дополнительной калибровки.

Горизонт	ROCSS	ROC-AUC	PR-AUC	Brier
24 ч	0.8034	0.9017	0.4065	0.1642
72 ч	0.3287	0.6644	0.1405	0.2851
120 ч	0.2352	0.6176	0.1246	0.3051
240 ч	0.1738	0.5869	0.1157	0.3001

Таблица 4.2: Итоговые метрики для региона Еуропа на сетке 0.25° по новому ноутбуку

При интерпретации таблицы 4.2 важно обратить внимание на два обстоятельства.

Во-первых, skill закономерно убывает с ростом горизонта прогноза. На 24 часах модель очень хорошо различает экстремальные и неэкстремальные случаи, на 72 часах качество остается полезным, а к 240 часам заметно снижается. Такая деградация ожидаема из-за накопления ошибки и ограниченной предсказуемости атмосферных процессов. Однако даже на 240 часах ROCSS остается положительным, что свидетельствует о сохранении некоторой прогностической информации.

Во-вторых, PR-AUC по абсолютному значению после 48 часов невелика. Это не является признаком «плохой модели» само по себе; в задачах экстремальных событий с редким положительным классом низкие значения PR-AUC типичны. Здесь важно сравнение не с абсолютной шкалой $[0, 1]$, а с базовой частотой события. В то же время высокий Brier score показывает, что вероятности в новом запуске нельзя напрямую трактовать как хорошо откалиброванные.

4.4. Сравнение стационарных и сеточных результатов

Хотя две части работы нельзя сравнивать напрямую «число к числу» из-за различия данных, объектов и протоколов оценки, сопоставление общих закономерностей оказывается информативным.

В стационарной части лучшими оказались бустинговые модели, причем XGBoost достиг среднего ROCSS 0.4469 на валидации, а на горизонте 24 часа показал ROCSS 0.3809. В новом сеточном запуске на горизонте 24 часа ROCSS выше, но на средних и дальних горизонтах значения оказываются ниже стационарного среднего. Такое сопоставление не следует интерпретировать как прямое превосходство одной постановки над другой: стационарная модель решает более локальную задачу, а сеточная модель прогнозирует полное поле, несколько горизонтов и несколько ансамблевых членов.

В сеточной части глубокая модель работает в существенно более сложной постановке. Она прогнозирует полное пространственное поле, несколько горизонтов прогноза и несколько ансамблевых членов. Поэтому более низкие значения метрик на дальних горизонтах сами по себе не означают меньшую ценность подхода. Именно глубокая модель делает возможными задачи, которые стационарная базовая модель решить не может: пространственно-согласованный прогноз, детекцию аномалий по картам квантилей и анализ пространственной структуры ошибок.




Рис. 4.3: Сравнение ROCSS по регионам и горизонтам прогноза. Тепловая карта показывает, как меняется качество при увеличении горизонта прогноза.




Рис. 4.4: Сравнение Brier score по регионам и горизонтам прогноза. Эта метрика дополняет ROCSS, так как учитывает не только ранжирование событий, но и численное качество вероятностей.

На рисунках 4.3 и 4.4 видно, что качество нельзя описать одной итоговой цифрой. Оно меняется по регионам и по горизонтам прогноза, причем дальние горизонты ожидаемо оказываются сложнее. Поэтому я рассматриваю набор метрик вместе, а не ограничиваюсь только одним показателем.

Если сформулировать вывод аккуратно, он звучит так: *станционные бустинги являются сильной и обязательной базовой моделью для локального прогноза, но глубокие нейросетевые модели необходимы в тех случаях, когда задача требует явной пространственной структуры и многогоризонтного сеточного прогноза*. Таким образом, две части работы не противоречат друг другу, а образуют логическую иерархию сложности.

4.5. Детекция аномалий как самостоятельная задача

Один из главных содержательных результатов работы состоит в том, что детекция аномалий в климатических данных может быть естественно интегрирована в прогнозную модель, а не рассматриваться как отдельный постобработочный этап. Это видно на обоих уровнях:

- в станционной постановке аномалия определяется через превышение $q_{0.9}$ и вероятность вычисляется из регрессионного прогноза;
- в сеточной постановке аномалия поддерживается через вспомогательную головную часть события и через вероятностную интерпретацию прогноза осадков.

Такой подход имеет несколько преимуществ. Во-первых, модель обучается на физически интерпретируемой величине — сумме осадков — и не теряет связи с основной метеорологической задачей. Во-вторых, вероятностная детекция строится на том же скрытом представлении, что и прогноз, а значит, использует максимально богатую информацию. В-третьих, это позволяет варьировать порог экстремальности без полного переобучения модели, если требуется перейти от $q_{0.9}$ к более жесткому или более мягкому критерию.




Рис. 4.5: Доля наблюдаемых экстремальных событий по горизонту прогноза и региону. График показывает базовую частоту положительного класса, относительно которой следует интерпретировать PR-AUC и метрики таблицы сопряженности.

На рисунке 4.5 показана базовая частота события. В новом запуске она остается близкой к ожидаемым 10%: для Европы значения составляют примерно 0.099 на всех горизонтах, а для Западной и Центральной Европы — около 0.100--0.102. Этот график важен, потому что без него легко неверно интерпретировать PR-AUC: при редком положительном классе даже умеренные абсолютные значения PR-AUC могут означать заметный выигрыш относительно климатологического уровня.




Рис. 4.6: Диаграмма надежности для вероятностной детекции экстремальных осадков. Она сравнивает предсказанные вероятности с фактическими частотами событий.




Рис. 4.7: ROC- и PR-кривые для Европы. ROC-кривая показывает качество ранжирования, а PR-кривая особенно важна из-за редкости экстремальных событий.

Рисунки 4.6 и 4.7 разделяют две разные стороны вероятностного прогноза. ROC/PR-кривые отвечают на вопрос, насколько хорошо модель ранжирует опасные случаи относительно обычных, а reliability diagram показывает, можно ли напрямую трактовать значения как откалиброванные вероятности. В новом запуске точки reliability diagram лежат существенно ниже диагонали идеальной калибровки, то есть модель переоценивает вероятность события. Для практического использования это различие существенно: модель может быть полезной для ранжирования риска, но при этом требовать дополнительной калибровки веро-

ятностей.

Пространственные примеры на рисунках 4.8 и 4.9 нужны не для замены численных метрик, а для проверки их содержательного смысла. По ним видно, где модель улавливает область повышенного риска, а где вероятностный прогноз может быть слишком сглаженным или смещенным относительно фактического пятна осадков. Для меня это важная часть анализа, потому что в сеточной задаче качество поля нельзя полностью описать одной усредненной метрикой.

С прикладной точки зрения это особенно важно для систем раннего предупреждения. Операционному пользователю часто нужны не только «ожидаемые миллиметры осадков», но и вероятность того, что будет превышен определенный опасный уровень. Архитектура, одновременно поддерживающая обе интерпретации, оказывается гораздо полезнее детерминированного прогноза без оценки риска.

4.6. Калибровка, смещение вероятностей и неопределенность

Помимо threshold-free метрик, таких как ROC-AUC и PR-AUC, необходимо отдельно анализировать калибровку вероятностей. В новом запуске именно калибровка является главным ограничением: средняя предсказанная вероятность события оказывается намного выше фактической частоты события.




Рис. 4.10: Средняя ошибка калибровки и максимальная ошибка калибровки по горизонтам прогноза для Европы.

высокая предсказанная вероятность экстремального события / score=0.6345 | старт=2020-12-27 12:00:00 | lead=72 ч | срок=2020-12-30 12:00:00




Рис. 4.8: Пример пространственного прогноза для случая с высокой предсказанной вероятностью экстремального события на горизонте 72 часа. Панели показывают наблюдаемые осадки, прогноз, локальный порог, вероятность события и маску фактического превышения.

риск пропуска экстремального события / score=0.0981 | старт=2020-12-24 12:00:00 | lead=72 ч | срок=2020-12-27 12:00:00




Рис. 4.9: Пример случая с риском пропуска экстремального события на горизонте 72 часа. Такой пример полезен для анализа не только успешных прогнозов, но и типичных ограничений модели.




Рис. 4.11: Среднее смещение вероятностного прогноза: разность между средней предсказанной вероятностью и фактической частотой события.

Горизонт	ECE	MCE	Средняя вероятность	Частота события
24 ч	0.2608	0.4503	0.3597	0.0992
72 ч	0.4297	0.5778	0.5288	0.0991
120 ч	0.4521	0.5980	0.5516	0.0996
240 ч	0.4482	0.6111	0.5471	0.0990

Таблица 4.3: Калибровочные показатели для региона Europe на сетке 0.25°

Рисунки 4.10 и 4.11, а также таблица 4.3, показывают, что вероятностный выход модели следует анализировать отдельно от качества ранжирования. Даже если ROC-AUC остается положительным, вероятности могут быть систематически завышены. В данном запуске средняя прогнозная вероятность на горизонтах 72--240 часов находится около 0.53--0.55, тогда как фактическая частота события близка к 0.10. Поэтому при операционном использовании такой модели необходимо добавить калибровочный слой, например isotonic regression или temperature scaling на отдельной валидационной выборке.




Рис. 4.12: Связь ансамблевого разброса и ошибки прогноза по горизонту прогноза. График используется как простая проверка того, несет ли ансамбль информацию о неопределенности.

Совместное распределение ансамблевого разброса и ошибки, lead=120 ч




Рис. 4.13: Совместное распределение ансамблевого разброса и ошибки для горизонта 120 часов. Такой вид графика позволяет увидеть не только средний тренд, но и плотность отдельных случаев.

Горизонт	Разброс, мм	MAE, мм	RMSE, мм	Bias, мм
24 ч	4.10	3.62	4.98	3.06
72 ч	6.12	5.88	6.92	5.05
120 ч	6.33	6.24	7.26	5.40
240 ч	6.47	6.36	7.38	5.50

Таблица 4.4: Ансамблевый разброс и ошибки прогноза осадков по выбранным горизонтам

Ансамблевая постановка нужна не только для усреднения прогноза, но и для оценки неопределенности. Рисунки 4.12 и 4.13 показывают, насколько ансамблевый разброс связан с фактической ошибкой. При этом таблица 4.4 выявляет еще одну особенность нового запуска: прогноз имеет выраженное положительное смещение по сумме осадков. Это согласуется с завышением вероятностей экстремального события и указывает, что модель склонна к переоценке влажных сценариев.




Рис. 4.15: Месячная диагностика смещения частоты экстремальных событий. Рисунок показывает, что ошибки модели имеют не только пространственную, но и сезонную структуру.

Рисунки 4.14 и 4.15 показывают, что ошибки модели неоднородны по пространству и сезону. Усредненная метрика может скрывать области с повышенной долей пропусков или ложных тревог, поэтому карты и месячные разрезы используются как отдельный источник информации о надежности прогноза.

4.7. Выводы по экспериментальной части

Результаты экспериментальной части можно свести к нескольким выводам.

Первый вывод состоит в том, что стационарные табличные модели с богатой инженерией признаков являются сильной базовой моделью для локального прогноза осадков. В рамках доступных экспериментов наилучшей моделью оказался XGBoost, а климатология показала сильный результат на дальнем горизонте 240 часов.

Второй вывод связан с региональной нейросетевой моделью Earthformer-M. Она демонстрирует устойчивое обучение и очень высокое качество ранжирования на ближайшем горизонте 24 часа, однако на средних и дальних горизонтах skill заметно снижается. Тем не менее ROCSS остается положительным, то есть модель извлекает полезный пространственно-временной сигнал для детекции аномальных осадков.

Третий вывод относится к вероятностной постановке. Детекция аномалий в климатических данных естественно формулируется как прогноз редкого события превышения кван-

тильного порога. Такая схема связывает регрессию и классификацию в одной экспериментальной процедуре.

Четвертый вывод касается практического применения. Полученные вероятности полезны для ранжирования риска, но в новом запуске они заметно завышены. Поэтому перед использованием в системе предупреждения необходимо выполнить отдельную калибровку вероятностей и затем выбирать порог вероятности с учетом цены пропуска и ложной тревоги.

Годовые средние карты диагностики, lead=120 ч, сетка 0.25°




Рис. 4.14: Годовые средние карты диагностики на горизонте 120 часов: аномалия, ошибка, средняя вероятность события, частота события, false alarm rate и miss rate.

Заключение

В работе были исследованы методы прогнозирования осадков и детекции аномальных осадочных событий на климатических данных. Основная идея состояла в том, чтобы рассматривать осадки не только как непрерывную величину, но и как источник редких событий, определяемых через превышение локального высококвантильного порога.

В стационарной части была построена полная процедура обработки данных RusWeather-GF: формирование лаговых и агрегированных признаков, временное разбиение выборки с учетом защитного интервала, обучение климатологии, линейной модели и градиентных бустингов. Результаты показали, что климатология является сильной базовой моделью, линейная модель недостаточно хорошо описывает нелинейную структуру осадков, а лучшие результаты среди табличных методов дают LightGBM и XGBoost. На горизонтах 24--120 часов XGBoost показывает наилучшие событийные метрики, тогда как на горизонте 240 часов климатология становится особенно сильным ориентиром.

Во второй части была рассмотрена региональная нейросетевая модель Earthformer-M для сеточных полей. Модель использует многоканальные последовательности метеорологических полей, отдельную обработку динамических и статических признаков, 3D-сверточный входной тракт, cuboid transformer-блоки, temporal attention pooling и условную выходную часть, зависящую от горизонта прогноза и номера ансамблевого члена. Обучение проводится в многозадачной постановке: одновременно оптимизируются регрессионные компоненты по осадкам, квантильная компонента ансамбля, soft-event loss, Brier-компонента и вспомогательная событийная голова.

По результатам обучения и проверки на валидационном периоде можно выделить несколько содержательных наблюдений. Во-первых, функция потерь устойчиво уменьшалась, а якорная метрика ROCSS выходила на плато после первых эпох, что показывает необходимость выбирать модель не только по общей функции потерь, но и по метрикам редких событий. Во-вторых, региональная модель показывает очень сильное качество ранжирования на горизонте 24 часа, но на средних и дальних горизонтах качество заметно снижается. В-третьих, новый запуск выявил существенное завышение прогнозных вероятностей и положительное смещение по сумме осадков, поэтому вероятностный выход требует отдельной калибровки перед практическим использованием.

Ключевой результат работы состоит в том, что детекция аномалий в климатических данных может быть встроена в задачу прогноза через квантильное определение события. В стационарной постановке это делается через сравнение непрерывного прогноза с локальным порогом станции, а в сеточной постановке — через локальную карту порогов и вероятностную оценку превышения. Такая схема сохраняет физическую интерпретацию целевой величины и одновременно дает инструмент для оценки риска экстремальных осадков.

В ходе работы были решены поставленные задачи: сформулирована событийная постановка, подготовлены стационарные признаки, обучены и сравнены базовые модели, опи-

сана региональная нейросетевая модель Earthformer-M, рассчитаны вероятностные метрики, построены графики калибровки, пространственных примеров, временных смещений и ансамблевой неопределенности.

Практическое значение работы заключается в том, что предложенная структура эксперимента может использоваться при разработке систем прогноза осадков на станциях и при построении пространственно согласованных систем оценки риска экстремальных осадков. Дальнейшее развитие работы может быть связано с более строгой калибровкой вероятностей, расширением набора регионов, доработкой функции потерь для уменьшения положительного смещения осадков и переносом подхода на другие типы климатических аномалий: температурные экстремумы, засухи и комбинированные гидроклиматические события.

Список использованных источников

1. Learning Skillful Medium-Range Global Weather Forecasting / R. Lam [и др.] // Science. — 2023. — Т. 382, № 6677. — С. 1416—1421. — DOI: [10.1126/science.adj2336](https://doi.org/10.1126/science.adj2336).
2. Accurate Medium-Range Global Weather Forecasting with 3D Neural Networks / K. Bi [и др.] // Nature. — 2023. — Т. 619, № 7970. — С. 533—538. — DOI: [10.1038/s41586-023-06185-3](https://doi.org/10.1038/s41586-023-06185-3).
3. FuXi: A Cascade Machine Learning Forecasting System for 15-Day Global Weather Forecast / L. Chen [и др.] // npj Climate and Atmospheric Science. — 2023. — Т. 6. — С. 190. — DOI: [10.1038/s41612-023-00512-1](https://doi.org/10.1038/s41612-023-00512-1).
4. Ronneberger O., Fischer P., Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation // Medical Image Computing and Computer-Assisted Intervention -- MICCAI 2015. — 2015. — С. 234—241. — DOI: [10.1007/978-3-319-24574-4_28](https://doi.org/10.1007/978-3-319-24574-4_28).
5. An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale / A. Dosovitskiy [и др.] // International Conference on Learning Representations. — 2021. — URL: <https://openreview.net/forum?id=YicbFdNTTy>.
6. A ConvNet for the 2020s / Z. Liu [и др.] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. — 2022. — С. 11976—11986. — DOI: [10.1109/CVPR52688.2022.01167](https://doi.org/10.1109/CVPR52688.2022.01167).
7. Wilks D. S. Statistical Methods in the Atmospheric Sciences. — 3-е изд. — Academic Press, 2011.
8. Gneiting T., Raftery A. E. Strictly Proper Scoring Rules, Prediction, and Estimation // Journal of the American Statistical Association. — 2007. — Т. 102, № 477. — С. 359—378. — DOI: [10.1198/016214506000001437](https://doi.org/10.1198/016214506000001437).
9. Murphy A. H. A new vector partition of the probability score // Journal of Applied Meteorology. — 1973. — Т. 12, № 4. — С. 595—600.
10. Jolliffe I. T., Stephenson D. B. Forecast Verification: A Practitioner's Guide in Atmospheric Science. — 2-е изд. — Wiley, 2012.
11. WeatherBench 2: A Benchmark for the Next Generation of Data-Driven Global Weather Models / S. Rasp [и др.] // Journal of Advances in Modeling Earth Systems. — 2024. — Т. 16, № 6. — e2023MS004019. — DOI: [10.1029/2023MS004019](https://doi.org/10.1029/2023MS004019).
12. WeatherBench: A Benchmark Data Set for Data-Driven Weather Forecasting / S. Rasp [и др.] // Journal of Advances in Modeling Earth Systems. — 2020. — Т. 12, № 11. — e2020MS002203. — DOI: [10.1029/2020MS002203](https://doi.org/10.1029/2020MS002203).
13. The ERA5 Global Reanalysis / H. Hersbach [и др.] // Quarterly Journal of the Royal Meteorological Society. — 2020. — Т. 146, № 730. — С. 1999—2049. — DOI: [10.1002/qj.3803](https://doi.org/10.1002/qj.3803).

14. FuXi-ENS: A Machine Learning Model for Medium-Range Ensemble Weather Forecasting / X. Zhong [и др.] // arXiv preprint arXiv:2405.05925. — 2024. — arXiv: [2405.05925](https://arxiv.org/abs/2405.05925).
15. Garg S., Rasp S., Thuerey N. WeatherBench Probability: A Benchmark Dataset for Probabilistic Medium-Range Weather Forecasting Along with Deep Learning Baseline Models // arXiv preprint arXiv:2205.00865. — 2022. — arXiv: [2205.00865](https://arxiv.org/abs/2205.00865).
16. FourCastNet: A Global Data-Driven High-Resolution Weather Model Using Adaptive Fourier Neural Operators / J. Pathak [и др.] // arXiv preprint arXiv:2202.11214. — 2022. — arXiv: [2202.11214](https://arxiv.org/abs/2202.11214).
17. Probabilistic Weather Forecasting with Machine Learning / I. Price [и др.] // Nature. — 2025. — T. 637, № 8040. — С. 84—90. — DOI: [10.1038/s41586-024-08252-9](https://doi.org/10.1038/s41586-024-08252-9).
18. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. — 2017. — T. 30.
19. Bishop C. M. Pattern Recognition and Machine Learning. — Springer, 2006.
20. Goodfellow I., Bengio Y., Courville A. Deep Learning. — MIT Press, 2016. — URL: <https://www.deeplearningbook.org/>.
21. An Extension of WeatherBench 2 to Binary Hydroclimatic Extreme Event Predictions / T. Zhao [и др.] // Geoscientific Model Development. — 2025. — T. 18. — С. 5781—5805. — DOI: [10.5194/gmd-18-5781-2025](https://doi.org/10.5194/gmd-18-5781-2025).
22. Bauer P., Thorpe A., Brunet G. The quiet revolution of numerical weather prediction // Nature. — 2015. — T. 525. — С. 47—55. — DOI: [10.1038/nature14956](https://doi.org/10.1038/nature14956).
23. Richardson D. S. Ensemble prediction systems // Seminar on Predictability of Weather and Climate. — 2007.
24. The ECMWF ensemble prediction system: Methodology and validation / F. Molteni [и др.] // Quarterly Journal of the Royal Meteorological Society. — 1996. — T. 122, № 529. — С. 73—119.
25. Roebber P. J. Visualizing multiple measures of forecast quality // Weather and Forecasting. — 2009. — T. 24, № 2. — С. 601—608.
26. Kingma D. P., Ba J. Adam: A Method for Stochastic Optimization // International Conference on Learning Representations. — 2015.
27. Hochreiter S., Schmidhuber J. Long short-term memory // Neural Computation. — 1997. — T. 9, № 8. — С. 1735—1780.
28. Learning phrase representations using RNN encoder-decoder for statistical machine translation / K. Cho [и др.] // Proceedings of EMNLP. — 2014. — С. 1724—1734.
29. Deep Residual Learning for Image Recognition / K. He [и др.] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. — 2016. — С. 770—778.

30. *Kingma D. P., Welling M.* Auto-Encoding Variational Bayes // International Conference on Learning Representations. — 2014.
31. *Ioffe S., Szegedy C.* Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift // International Conference on Machine Learning. — 2015. — C. 448—456.
32. *Ba J. L., Kiros J. R., Hinton G. E.* Layer Normalization // arXiv preprint arXiv:1607.06450. — 2016.
33. *Loshchilov I., Hutter F.* Decoupled Weight Decay Regularization // International Conference on Learning Representations. — 2019.
34. *Hanley J. A., McNeil B. J.* The meaning and use of the area under a receiver operating characteristic curve // Radiology. — 1982. — T. 143, № 1. — C. 29—36.
35. *Davis J., Goadrich M.* The relationship between Precision-Recall and ROC curves // Proceedings of the 23rd International Conference on Machine Learning. — 2006. — C. 233—240.
36. On Calibration of Modern Neural Networks / C. Guo [и др.] // International Conference on Machine Learning. — 2017. — C. 1321—1330.
37. *Lakshminarayanan B., Pritzel A., Blundell C.* Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles // Advances in Neural Information Processing Systems. — 2017.
38. *Gal Y., Ghahramani Z.* Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning // International Conference on Machine Learning. — 2016. — C. 1050—1059.
39. *Kendall A., Gal Y.* What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision? // Advances in Neural Information Processing Systems. — 2017.
40. *Willmott C. J.* Some comments on the evaluation of model performance // Bulletin of the American Meteorological Society. — 1982. — T. 63, № 11. — C. 1309—1313.